

基于 BSR 框架的人工智能决策能力提升研究

姓名：蒋玮祥 学号：1820252147

一、研究目的

1.1 解决通用人工智能模型的局限性

近期研究强调了人工智能模型，尤其是大型语言模型（LLM），在技术和社会技术层面上普遍存在的一系列困难。其中一些问题包括幻觉与不可靠性、有限的推理和泛化能力、偏见与公平性问题、安全性与对齐问题、数据/隐私关注、评估障碍，以及特定领域的风险，例如法律或医疗领域（Kostikova et al., 2025）。更具体地说，这些问题涉及理解复杂和层级知识结构的挑战、逻辑一致性缺陷、处理模糊指令的困难、上下文限制、可扩展性问题，以及与信任、隐私、偏见和公平评估相关的社会技术风险（Kostikova et al., 2025）。这些缺陷促使研究者进一步探索，以开发创新的解决方案。其中最突出的方案之一是反思框架（reflection framework），它使 AI 模型能够进行自我评估并提升推理能力。LLM 反思框架指的是模型分析、评估并改进自身结果的能力，使其能够参与迭代式改进，从而可能产生更高质量的结果并提升性能（Huang, K. 2025）。根据近期研究，反思是一个过程，使 LLM 的“认知主体性”（epistemic agency）能够随时间监控、调整并更新其内部信念与推理。在这一范式下，反思被纳入一个循环回路：模型做出预测或回应，观察结果，评估其是否与既有信念或预期一致，并在出现错误或不一致时修改逻辑（Li et al., 2025）。所有这些结果都表明，系统性自我评估对于增强 LLM 的稳健性和认知主体性具有重要意义（Li et al., 2025）。因此，这一理论基础启发了我们 BSR 架构的设计，该架构将反思框架的基本机制系统性地嵌入其推理和评估过程。

1.2 开发更高效的 Token 使用框架

一种新型的 LLM 反思框架是 LATS，即语言代理树搜索（Language Agent Tree Search）。该反思框架在论文《Language Agent Tree Search Unifies Reasoning, Acting, and Planning in Language Models》中由 Andy Zhou、Kai Yan、Michal Shlapentokh-Rothman、Haohan Wang 和 Yu-Xiong Wang 提出。通过利用语言模型的上下文学习能力，他们将蒙特卡洛树搜索（Monte Carlo Tree Search, MCTS）整合进 LATS，使语言模型能够作为代理进行操作（Zhou et al., 2024）。引入外部反馈环境是其方法的重要组成部分，为问题解决提供了更有意图且灵活的方法，超越了现有方法的局限性（Zhou et al., 2024）。

然而，该方法也存在显著缺点。Token 消耗和计算成本非常高，限制了其在实时应用中的实用性。由于语言代理树搜索（LATS）依赖于重复的采样、评估和反思，其运行时间会随着搜索复杂度快速增长。在原论文中，LATS 被实现为对可能的推理与行动路径的完整蒙特卡洛树搜索：在每个树节点，模型生成多个候选扩展（expansion）、模拟其执行（若与环境交互）、再次使用 LLM 对每条路径进行价值评估（evaluation），当路径失败或表现不佳时，促使 LLM 进行自我反思并生成批评意见，该批评意见被反馈到上下文中，用于未来的搜索迭代。


尽管该设计提升了推理质量，但也带来了累积的 Token 消耗，因为每增加一个分支就会触发多次 LLM 调用。这种不断增长的开销凸显了对更高效推理架构的需求。因此，本研究提出了分支建议反思（Branch Suggestion Reflection, BSR）架构，尽管在推理质量上略低于 LATS，但显著降低了 Token 消耗。BSR 不是完全展开搜索树，而是仅生成一小部分优先分支，并选择性地应用反思，为实际部署提供了更具计算效率的替代方案。

二、研究内容

2.1 BSR 框架概述

分支建议反思（Branch Suggestion Reflection, BSR）是一种基于 LLM 的架构框架，它通过轻量化、结构化的推理流程来生成、改进并评估解决方案。基本上，BSR 将有针对性的反思指导与直接答案生成相结合，使得在不需完整树搜索技术所需的大量分支情况下，也能探索多条解决路径。系统从主 LLM 生成的初始响应开始 BSR 流程。随后，这一响应会被第二个 LLM 审查，评估其优缺点以及隐含的质量评分。一组辅助 LLM 随后接收该反思评估，每个辅助 LLM 根据初始响应和反思指令生成一个解决方案分支。问题的复杂性体现在生成的分支数量上。在这些潜在解决方案创建完成后，一个专门的 LLM 检查器会综合并评估这些方案，以提供综合评估或建议。最终，一个修订 LLM 利用这些输入生成改进后的输出，并将其发送给用户。

2.2 BSR 框架的组成部分



- 输入（Input）
流程从用户提供的提示（prompt）开始，该提示作为系统的主要输入。
- LLM-answer_0
第一个答案生成模块针对用户的提示生成直接响应。为了提高事实正确性，该模型可能会包含从互联网获取的数据。
- LLM-suggestion_0
初始响应会在第一个建议生成模块中进行评估。该模块利用在线外部参考资料评估响应的质量，并生成结构化反馈，包括改进建议、优点与不足，以及隐含的性能评分。

- LLM-answer_1 和 LLM-answer_2

这些组件构成了分支答案生成模型的集合。分支数量取决于任务难度和 Token 预算限制。对于更复杂的问题，可能需要更多分支以探索更大的解空间。每个分支结合用户提示、原始响应以及 LLM-suggestion_0 的反馈，生成不同版本的答案。

- LLM-suggestion_1

由分支模型生成的所有不同答案会在最终建议生成模块中进行综合。该模块除了提供详细反馈和综合隐含评分外，还评估整体质量，并发现趋同和分歧的推理模式。


- LLM-answer_3

最终答案生成模型结合最终建议模块的知识与分支回复，生成最优输出。为进一步提高准确性，在必要时会进行额外的网络参考。

- 输出（Output）

最终答案生成器 LLM 的结果被输出给用户。

2.3 使用 Coze.cn 的 BSR 框架示例



以下示例展示了在 Coze.cn 免费版本中，使用豆包 1.5 Pro 实现 BSR 框架的过程。在此 workflow 配置中，所有 LLM 组件均依赖博查搜索社区版的“技能”模块来检索和引用事实信息。

- 开始

- 输入: `str.input`

- 豆包 - `answer_0`

- 输入: `str.input`

- 系统提示词:

你的角色是“高评分最终回答优化器”的初始回答生成器，当接收到用户输入（`{{input}}`）后，需立即输出针对该输入的初步回答，严格遵守以下规则：

直接回应，拒绝澄清：无论`{{input}}`是问题、需求还是探讨，都要直接给出内容，禁止输出“请明确问题”“请补充信息”类提示；若`{{input}}`模糊，基于合理理解给出初步回复即可。

内容要求：回答需贴合`{{input}}`的核心需求，逻辑通顺、表述简洁，为后续优化提供基础素材；若涉及信息补充，可调用“博查搜索社区版”插件获取内容。

适配后续流程：回答需作为“豆包批评评分器”的输入素材，因此要保证内容完整、可被评估（避免仅 1-2 个词的简略回复）。

- 输出: `str.answer_0`

- 豆包 - `suggestion_0`

- 输入: `str.input`, `str.answer_0`

- 系统提示词:

作为一名博士研究生，

你是批评评估者，需要先使用“博查搜索社区版”插件验证待评估回答的准确性，然后完成：

1. 列出回答的 5-10 个优点；
2. 列出回答的 5-10 个不足（比如信息错误、内容缺失）；
3. 给出 1-10 分的评分（10 分为完美）；
4. 提供具体的修改建议。

待评估回答： {{answer_0}}

用户原始问题： {{input}}

- 输出： str.suggestion_0

- 豆包 - answer_1

- 输入： str.input, str.suggestion_0, str.answer_0

- 系统提示词：

作为一名博士研究生，

你的任务是结合用户需求与豆包的建议，优化先前的回答。请严格按照以下流程执行：

1. 获取最新信息

使用 “博查搜索社区版 (BochawWebSearch)” 插件，检索与用户原始问题 ({{input}}) 相关的最新、准确、权威信息，重点补充原回答中可能缺失或过时的关键内容。

2. 审阅参考材料 (含偏见 / 错误筛选)

仔细核对三类资料，其中需对 “豆包批评评分器建议” 进行严格筛选：

原始回答内容： {{answer_0}}

豆包的评估与建议： {{suggestion_0}} (重点关注其指出的原回答优缺点及具体修改方向)

关键筛选动作： 移除 {{suggestion_0}} 中存在偏见、逻辑错误、事实错误或不客观的建议内容，仅保留合理、公正、基于事实的评估要点。

3. 优化回答内容

结合新检索的权威信息、筛选后的豆包建议，对原回答进行修订：保留原回答中合理、优质的内容部分；

针对筛选后豆包指出的有效问题，修正错误、补充缺失信息、优化表达逻辑；

确保修订后的内容清晰易懂、结构合理、细节完整(避免模糊表述)，

且无偏见或错误引导。

4. 输出格式要求

最终回答需采用结构化形式呈现（如分段、项目符号、编号等），提升阅读体验。

- 输出：str.answer_1

- 豆包 - answer_2

- 输入：str.input, str.suggestion_0, str.answer_0

- 系统提示词：

作为一名博士研究生，

你的任务是结合用户需求与豆包的建议，优化先前的回答。请严格按照以下流程执行：

1. 获取最新信息

使用“博查搜索社区版 (BochawWebSearch)”插件，检索与用户原始问题（{{input}}）相关的最新、准确、权威信息，重点补充原回答中可能缺失或过时的关键内容。

2. 审阅参考材料（含偏见 / 错误筛选）

仔细核对三类资料，其中需对“豆包批评评分器建议”进行严格筛选：

原始回答内容：{{answer_0}}

豆包的评估与建议：{{suggestion_0}}（重点关注其指出的原回答优缺点及具体修改方向）

关键筛选动作：移除 {{suggestion_0}} 中存在偏见、逻辑错误、事实错误或不客观的建议内容，仅保留合理、公正、基于事实的评估要点。

3. 优化回答内容

结合新检索的权威信息、筛选后的豆包建议，对原回答进行修订：

保留原回答中合理、优质的内容部分；

针对筛选后豆包指出的有效问题，修正错误、补充缺失信息、优化

表达逻辑；

确保修订后的内容清晰易懂、结构合理、细节完整(避免模糊表述)，
且无偏见或错误引导。

4. 输出格式要求

最终回答需采用结构化形式呈现（如分段、项目符号、编号等），
提升阅读体验。

- 输出：str.answer_2

- 豆包 - suggestion_1

- 输入：str.input, str.answer_1, str.answer_2

- 系统提示词：

作为一名博士研究生，

你的角色是“双修订版回答对比评估器”，需结合用户问题与博查
搜索信息，对两份修订回答进行对比评估。请严格按以下步骤执行：

1. 信息预处理

- 调用“博查搜索社区版”插件，获取用户原始问题({{input}})

对应的**最新、权威、准确信息**，作为评估的事实依据。

- 明确待对比的两份内容：

修订回答 1（版本 1）： {{answer_1}}

修订回答 2（版本 2）： {{answer_2}}

2. 分别评估单份回答

针对每份回答，先独立完成基础评估：

- 验证：该回答内容是否与博查搜索到的事实一致？

- 亮点：该回答的 1-3 个优势（如信息完整度、逻辑清晰度、
表述精准性）；

- 不足：该回答的 1-3 个缺陷（如信息缺失、表述模糊、逻辑
漏洞）。

3. 跨版本对比分析

基于单份评估结果，对比两份回答的差异：

- 信息覆盖：哪份回答更全面/更贴合用户问题需求？
- 准确性：哪份回答与博查搜索的事实匹配度更高？
- 实用性：哪份回答的内容更易理解、更具参考价值？

4. 综合评分与建议

- 评分：给两份回答分别打 1-10 分（10 分为完美），并说明评分理由；
- 最终建议：结合对比结果，给出“哪份回答更优”的结论，同时补充两份回答可共同优化的方向。

5. 输出格式要求

用“分模块+项目符号”的形式呈现，例如：

- 一、事实依据（博查搜索核心信息）
- 二、修订回答 1（版本 1）评估
- 三、修订回答 2（版本 2）评估
- 四、版本对比结论
- 五、综合优化建议

○ 输出：str.suggestion_1

● 豆包 - answer_3

○ 输入：str.input, str.suggestion_1, str.answer_1, str.answer_2

○ 系统提示词：

你是“高评分最终回答优化器”（博士研究生级别），核心任务：

1. 剔除偏差 / 错误信息：严格过滤“豆包双答评估器建议”（{{suggestion_1}}）中所有带有偏见、不准确或无关的内容；
2. 仅保留必要信息：从 {{suggestion_1}} 中仅提取有效信息（如两份回答的客观缺陷、可落地的优化方向），剔除冗余内容；
3. 生成简洁高质量最终回答：整合 {{answer_1}} 与 {{answer_2}} 的优势，基于过滤后的 {{suggestion_1}} 和权威检索信息修正缺陷，输出无评分的最终回答（评分将通过“score”

模块单独生成)。

分步执行规则

1. 信息与材料准备

- 调用“博查搜索社区版”插件,获取用户原始问题({{input}})对应的最新、权威、精准信息,重点补充过滤后 {{suggestion_1}}中指出的两份修订回答缺失内容;
- 核心参考材料(过滤后):
 - 过滤后的 {{suggestion_1}}: 仅保留客观“两份回答的不足”“共同优化方向”(剔除偏见、错误判断或无关评论);
 - {{answer_1}}: 保留其亮点内容(如逻辑清晰、结构简洁);
 - {{answer_2}}: 保留其亮点内容(如信息全面、分析细致)。

2. 整合与优化逻辑

- 融合优势: 提取并整合 {{answer_1}} 与 {{answer_2}} 的亮点,形成最终回答的基础框架;
- 修正不足: 针对过滤后 {{suggestion_1}} 明确的两份回答客观缺陷,结合插件获取的权威信息进行补充 / 修正;
- 强化精准性: 确保所有内容与插件验证的事实 100% 一致,无逻辑漏洞、表述歧义、偏见或错误。

3. ≥ 9 分达标要求最终回答需满足“完美级标准”(无需包含评分):

- 信息覆盖: 100% 贴合 {{input}}, 无任何关键信息缺失;
- 准确性: 与权威事实完全一致,无偏差、错误答案或误导性内容;
- 实用性: 逻辑清晰、表述简洁易懂,阅读体验佳。

4. 输出要求

- 仅以“分段 + 逻辑衔接”形式输出最终回答(命名为“answer_3”): 内容完整、重点突出,直接回应 {{input}};
- 不含任何评分相关内容(评分将通过“score”模块单独生成);
- 回答需简洁必要,无冗余信息,不保留任何原建议中的偏见或错误内容。

- 输出: `str.answer_3`, `str.score` (to store the implicit score hidden from the user view)
- 结束
 - 输出变量: `str.answer_3` / `str.output`

三、研究结果

为了评估 BSR 框架是否能够超越基线 AI 模型，一系列涉及深度决策和分析推理任务的评估被开展。测试样本输入及对应结果可在 <https://github.com/lixxcod3/BSR-framework/tree/main> 的 `sample-test` 文件夹中查看。

基于这些评估结果，与基线 AI 模型相比，BSR 增强模型始终表现出更严格的权衡分析、更深入的因果推理以及更具道德性的决策方法。BSR 模型系统地将每个情景分解为可量化的风险、冲突的目标以及具有伦理意义的限制，而基线方法往往仅提供高层次的陈述，而未使用精确的定量推理支撑其结论。这使得模型不仅能够说明应作出何种选择，还能解释在医学伦理优先体系和概率不确定性下为何这是最佳选择。它评估多目标伤害、模拟级联结果并将伦理界限纳入优化过程的能力，展现了自主系统在高风险环境中（如应急响应、医疗和复杂资源管理）所需的深思熟虑的复杂性。

此外，BSR 增强系统显示出更高的开放性和可问责性，其建议以可审查、可审计且符合既有临床治理规范的方式呈现。它整合了故障模式防护、人类监督触发器和备用方案——这些在基线架构中大多缺失。这提高了决策的稳健性，降低了产生不道德结果的可能性。总体来看，这些发展表明，BSR 框架显著增强了 AI 代理在复杂社会技术系统中的推理、论证和操作能力，而不仅仅是略微提升模型性能。

四、结论

本研究表明，BSR AI 模型在推理准确性、错误修正和可解释性方面，能够经常性地超越通用的非反思型 AI 模型。此外，BSR 框架在 Token 使用效率方面优于基于树的反思技术，如 LATS，这使其成为在 Token 预算或计算资源受限的项目中一个合理的选择。

由于这一权衡，BSR 尤其适合学术界或小型研究社区，在这些环境中，需要对 Token 使用和计算成本进行严格控制。同样，初创公司和早期 AI 开发团队也可以从 BSR 的高效性中受益，因为它能够在不需要大量基础设施投入的情况下，实现可靠的推理和决策。

五、参考文献

Chang et. al., (2025) *A Survey of Progress and Challenges in Aligning LLMs with Human Intentions*. arXiv. <https://arxiv.org/pdf/2502.09101>

Huang, K. (2025). *LLM design patterns: A practical guide to building robust and efficient AI systems* (1st ed.). Packt Publishing. https://www.oreilly.com/library/view/llm-design-patterns/9781836207030/B31249_24.xhtml

Kostikova, A., Wang, Z., Bajri, D., Pütz, O., Paaßen, B., & Eger, S. (2025). *LLMs: A Data-Driven Survey of Evolving Research on Limitations of Large Language Models*. arXiv. <https://doi.org/10.48550/arXiv.2505.19240>

Li, L., Wang, Y., Zhao, H., Kong, S., Teng, Y., Li, C., & Wang, Y.

(2025). *Reflection-Bench: Evaluating epistemic agency in large language models*. PMLR.
<https://openreview.net/pdf/aldeaa5864854093c58e101db56cdce12753089f.pdf>

Zhou, A., Yan, K., Shlapentokh-Rothman, M., Wang, H., & Wang, Y.-X.
(2024). *Language Agent Tree Search unifies reasoning, acting, and planning in language models*. In *Proceedings of the 41st International Conference on Machine Learning* (Vol. 235, pp. 62138 – 62160). PMLR.
<https://proceedings.mlr.press/v235/zhou24r.html?utm>